

Сверточные нейронные сети для задачи сегментации



Кафедра
технологий
проектирования
сложных
технических
систем

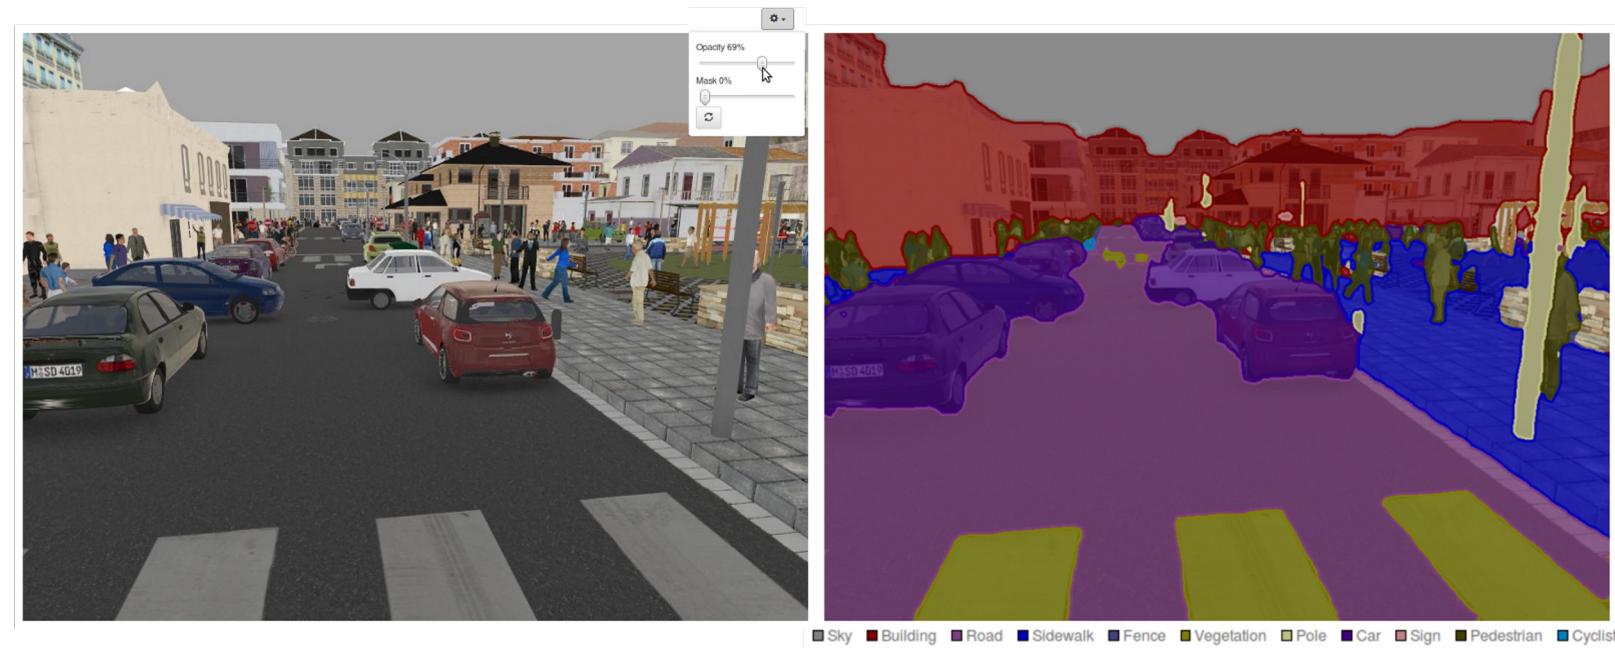
План лекции

- Постановка задачи сегментации изображений
- Базовые подходы к построению архитектур encoder-decoder
- Некоторые техники обучения моделей

Основные направления в CV

Сегментация

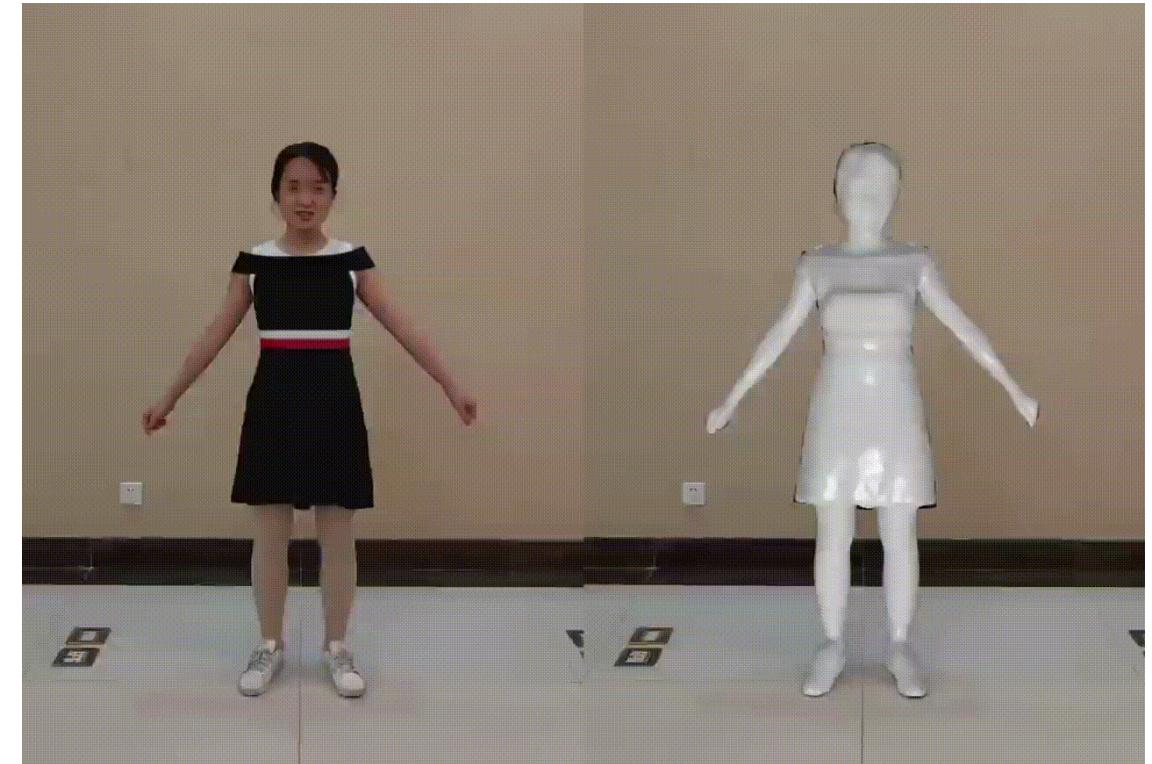
Решается задача
классификации, но
попиксельной



Основные направления в CV

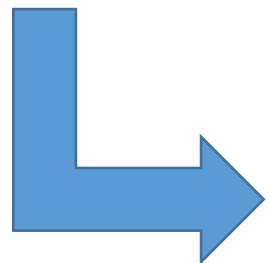
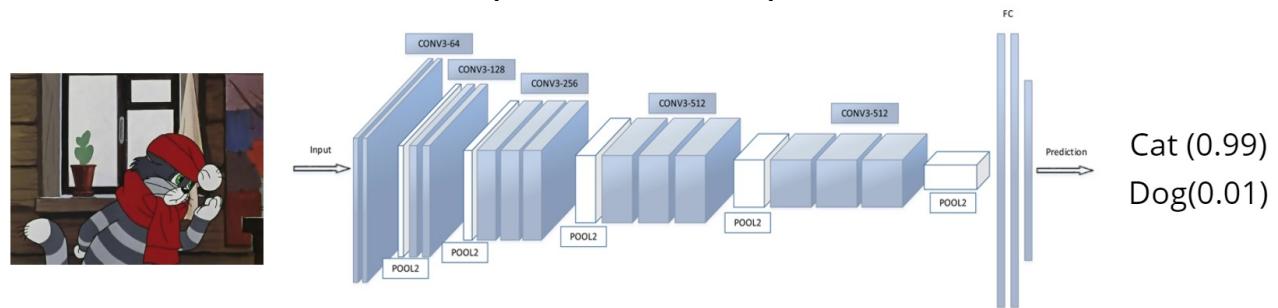
Построение 3D Объектов

Решается задача
построения объемного
объекта (obj-файл) по
двумерному
изображению



Классификация

Классификация изображения



Классификация пикселей изображения



- Сегментация — попиксельная классификация
- Не требует большого количества данных
- Все сегментационные модели — это архитектуры вида FCN

Типы сегментации

Semantic segmentation



Input

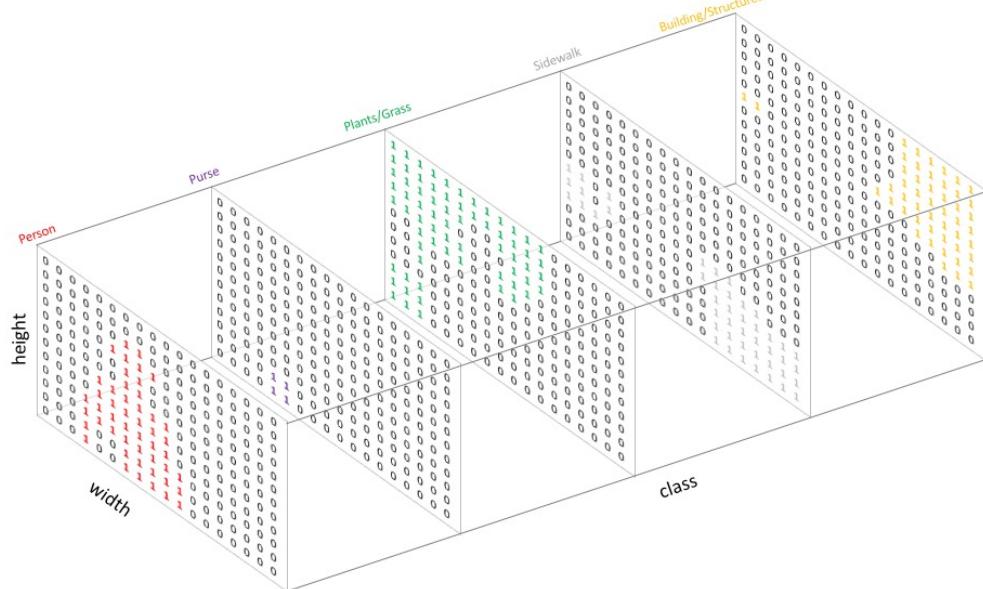
segmented →

- 1: Person
- 2: Purse
- 3: Plants/Grass
- 4: Sidewalk
- 5: Building/Structures

3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	5	5	5	5	5	5
3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	5	5	5	5	5	5
3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	5	5	5	5	5	5
3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	5	5	5	5	5	5
3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	5	5	5	5	5	5
5	5	3	3	3	3	3	1	1	1	3	3	3	3	3	3	3	5	5	5	5	5	5
4	4	3	4	1	1	1	1	1	1	1	3	3	3	3	3	3	5	5	5	5	5	5
4	4	3	4	1	1	1	1	1	1	1	1	4	4	4	4	4	4	4	5	5	5	5
4	4	4	1	1	1	1	1	1	1	1	1	1	4	4	4	4	4	4	4	4	4	4
3	3	3	1	1	1	1	1	1	1	1	1	1	1	1	1	1	4	4	4	4	4	4
3	3	3	1	2	2	1	1	1	1	1	1	1	1	1	1	1	4	4	4	4	4	4
3	3	3	1	2	2	1	1	1	1	1	1	1	1	1	1	1	4	4	4	4	4	4

One-hot encoding

Semantic Labels

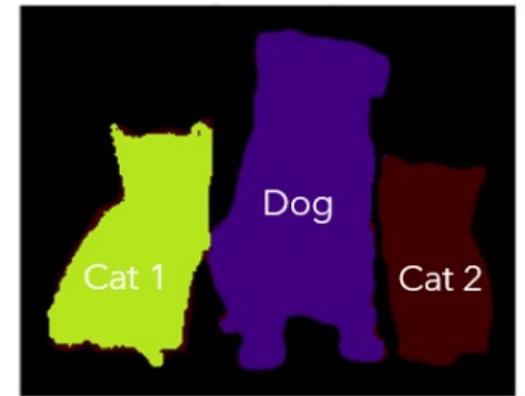


Instance segmentation

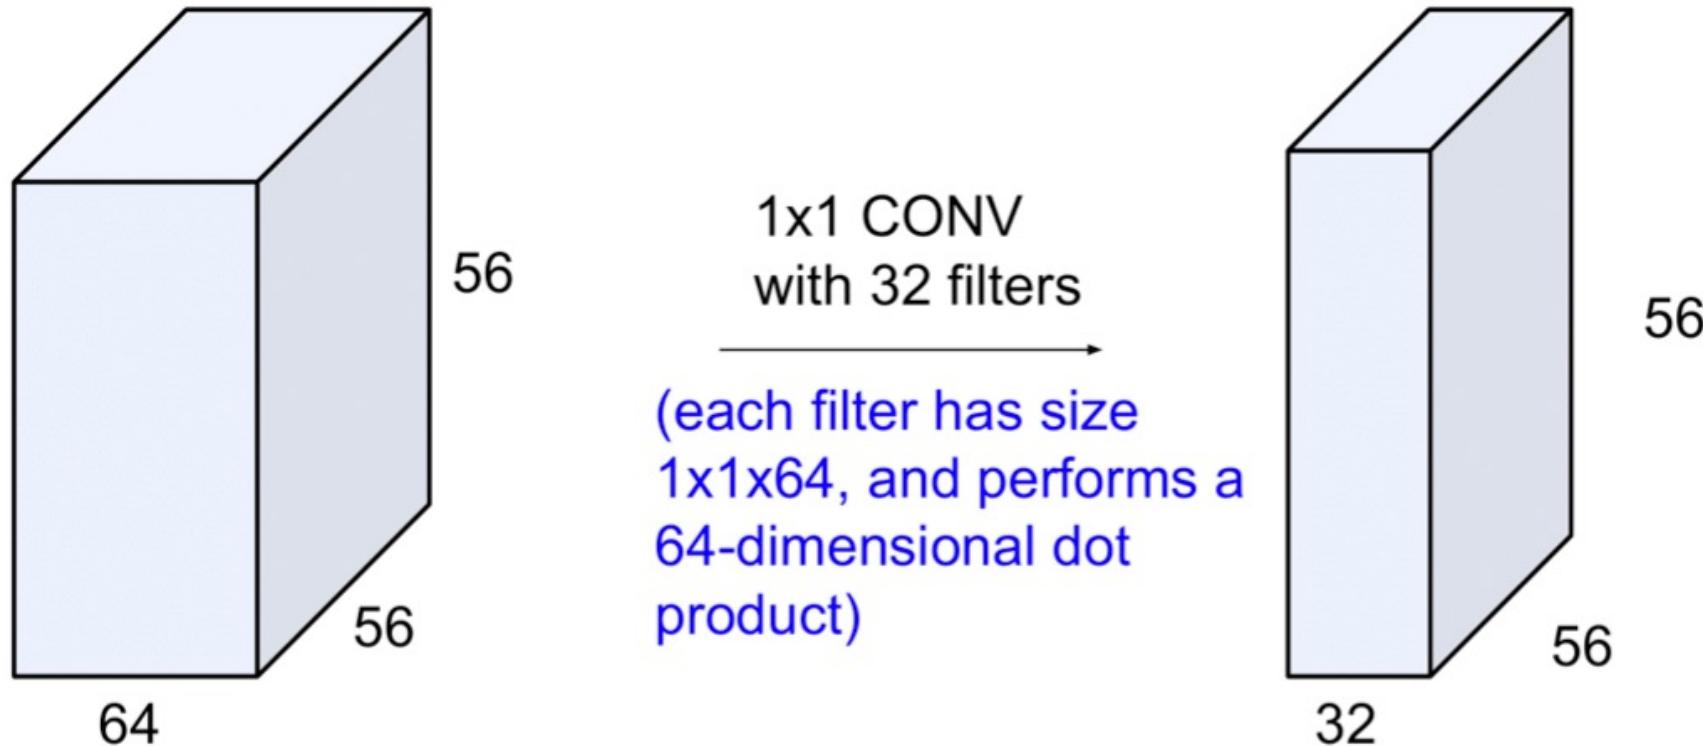
Original Image



Instance Segmentation

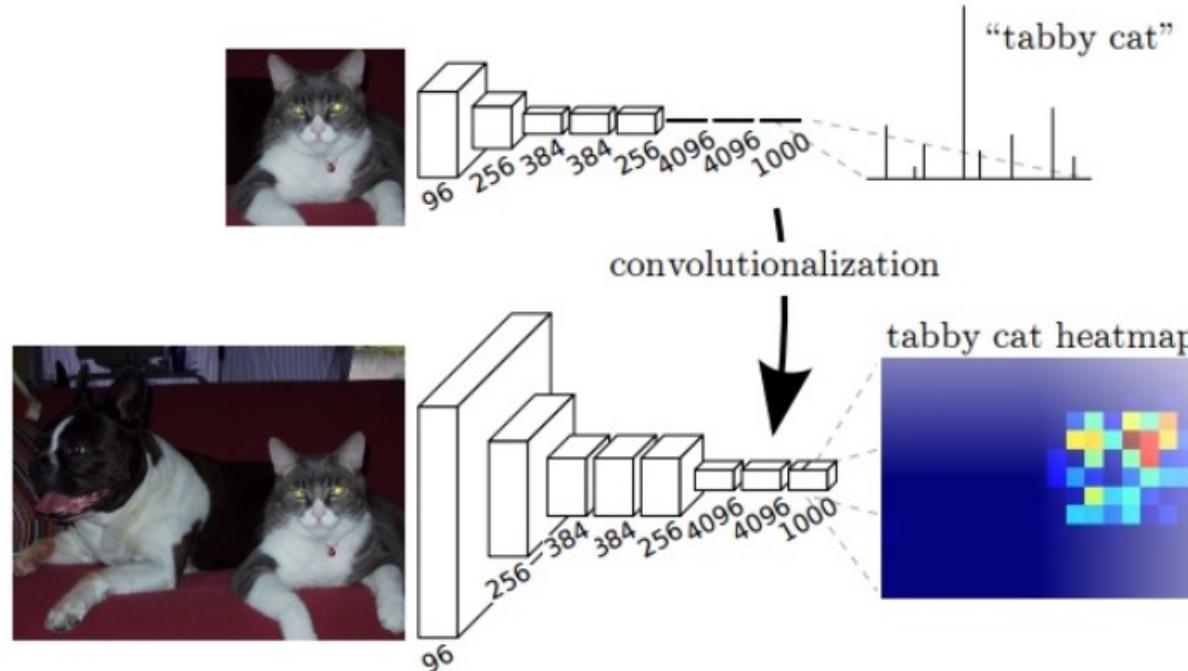


Conv1x1 Recap



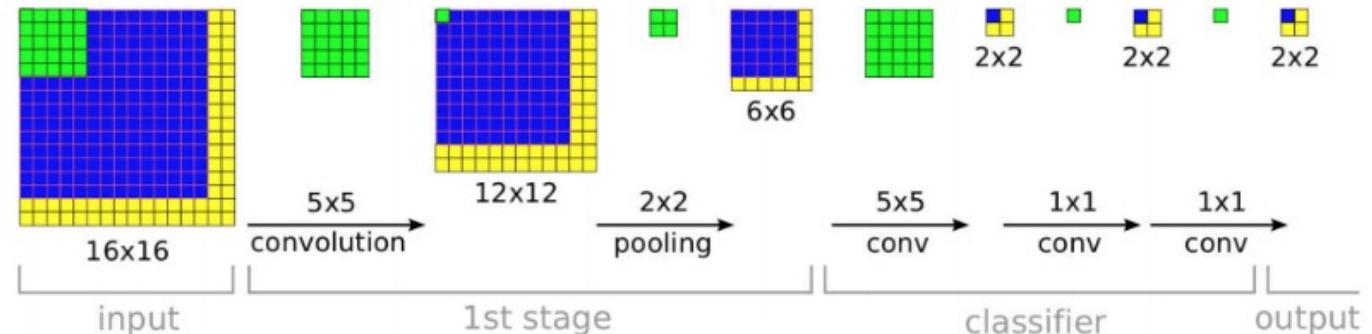
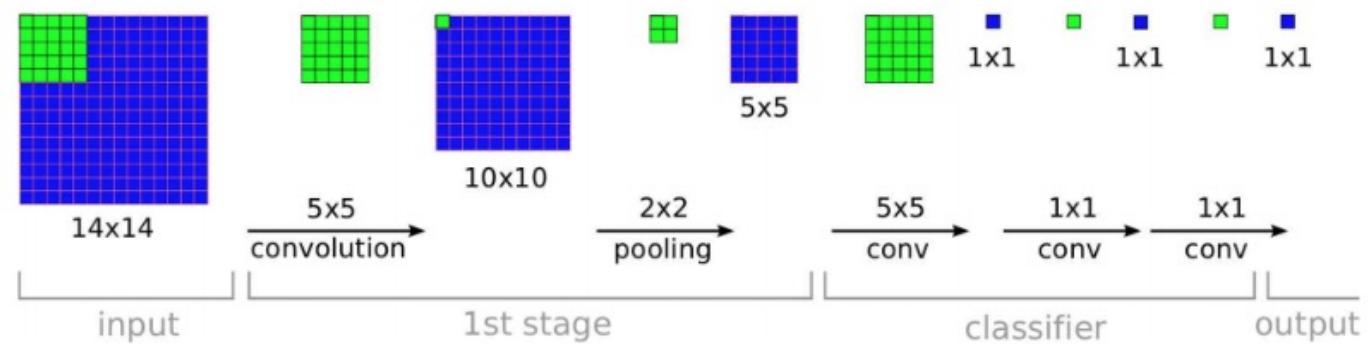
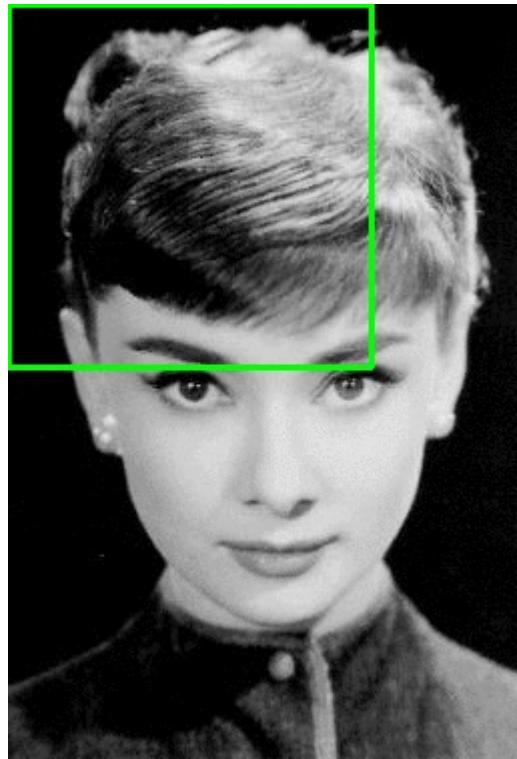
Source: Stanford CS231n Lecture 5 2017 by Fei-Fei Li & Justin Johnson & Serena Yeung

Fully Convolutional Network: FCN

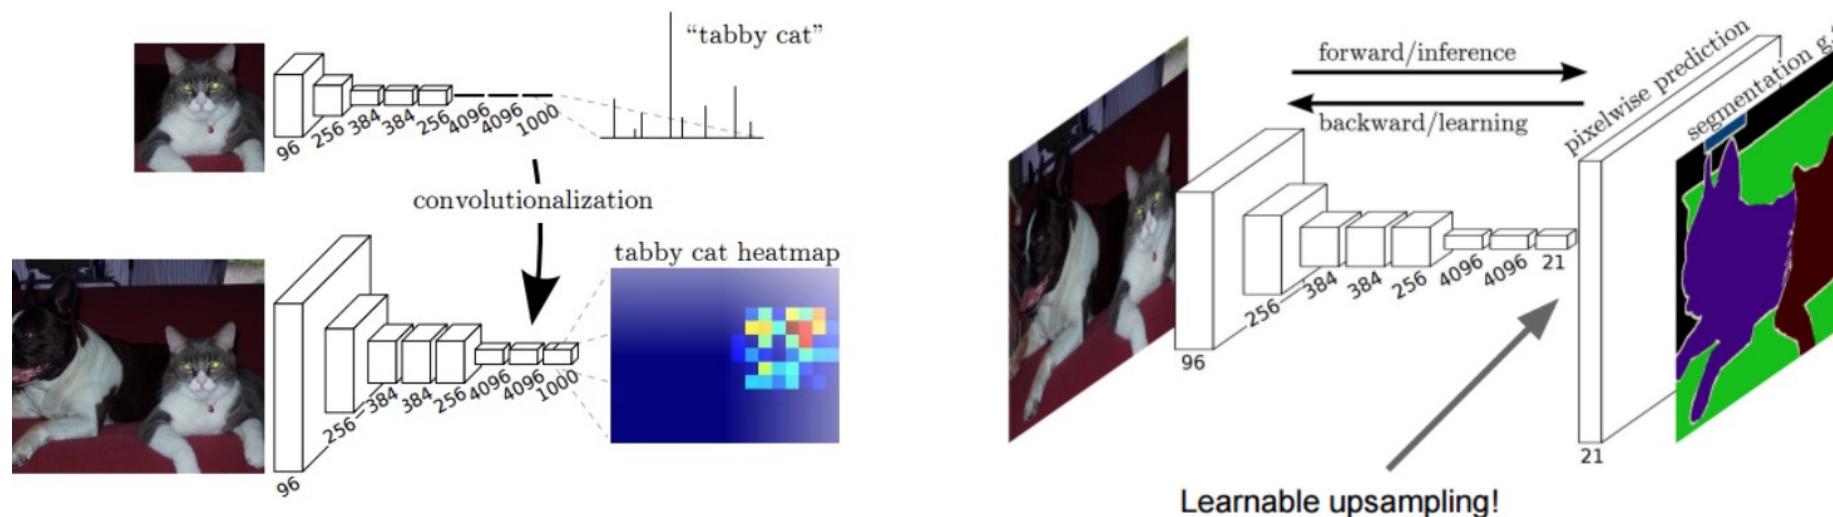


- Убираем FC и заменяем на Conv
- Получаем меньше обучаемых параметров
- На вход может получить изображение любого размера

FCN = Efficient Sliding Window



Fully Convolutional Network: FCN



- Убираем FC и заменяем на Conv
- Добавляем декодер

Upsampling

Nearest neighbor
Nearest Neighbor

1	2
3	4



1	1	2	2
1	1	2	2
3	3	4	4
3	3	4	4

Output: 4 x 4

Input: 2 x 2

Bed of nails

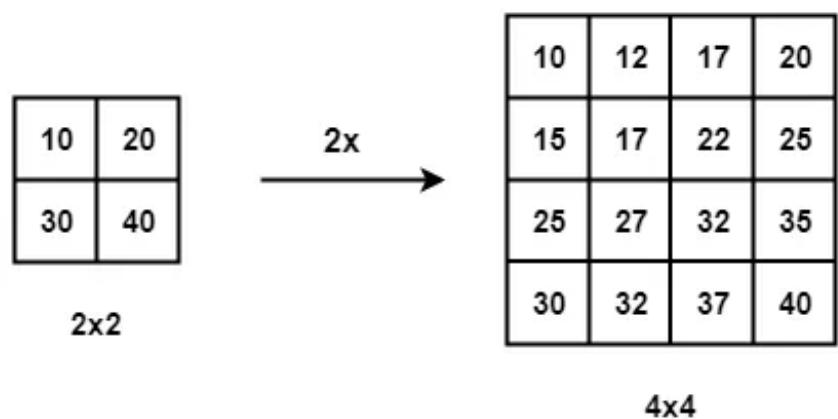
1	2
3	4



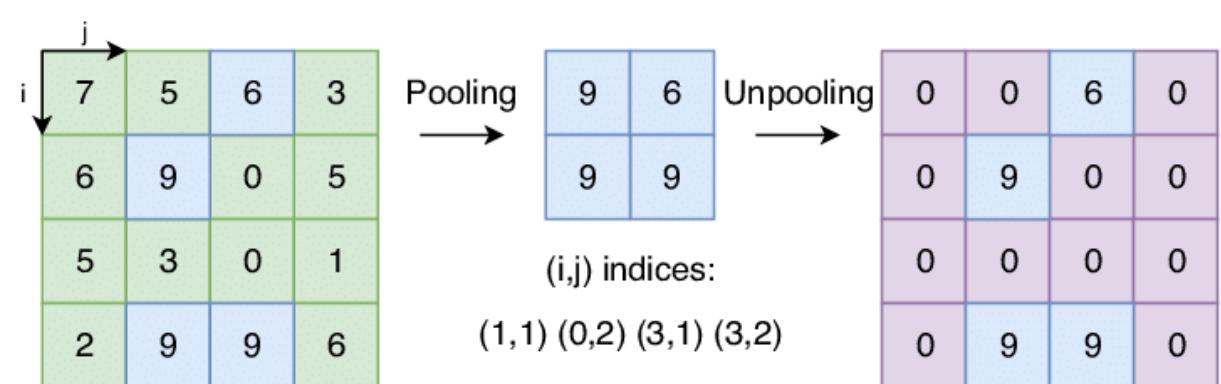
1	0	2	0
0	0	0	0
3	0	4	0
0	0	0	0

Upsampling

Bilinear interpolation

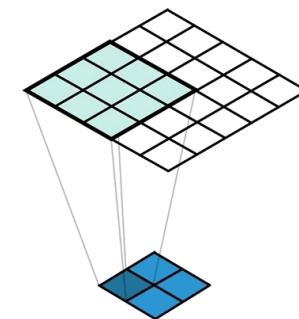
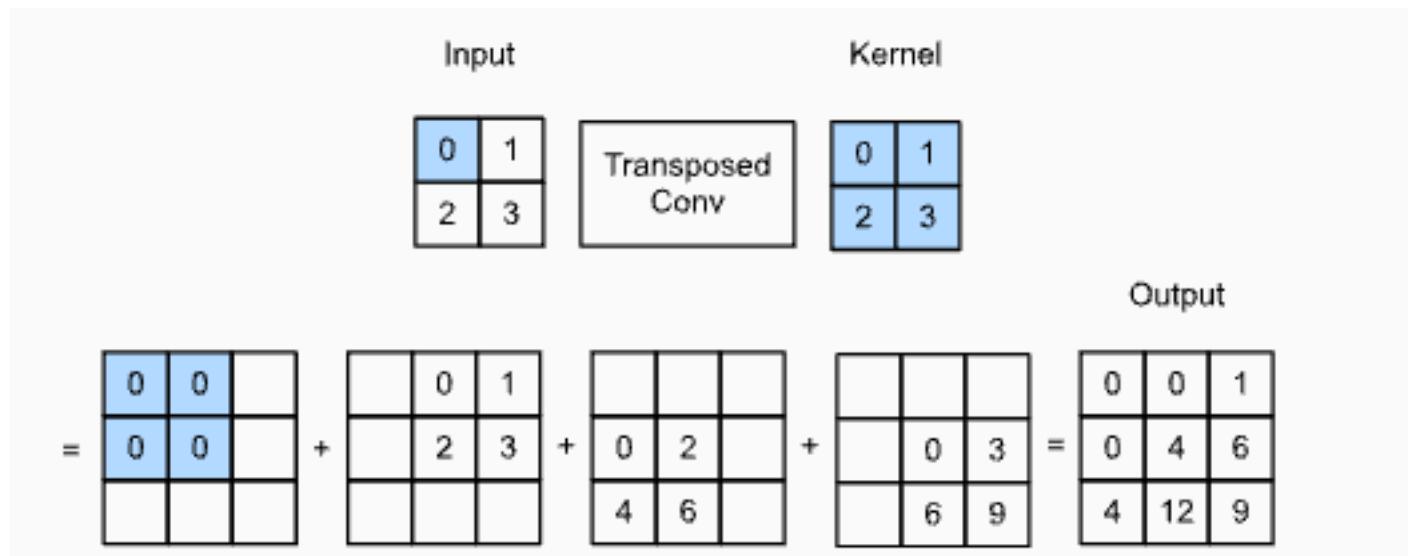


Max-Unpooling



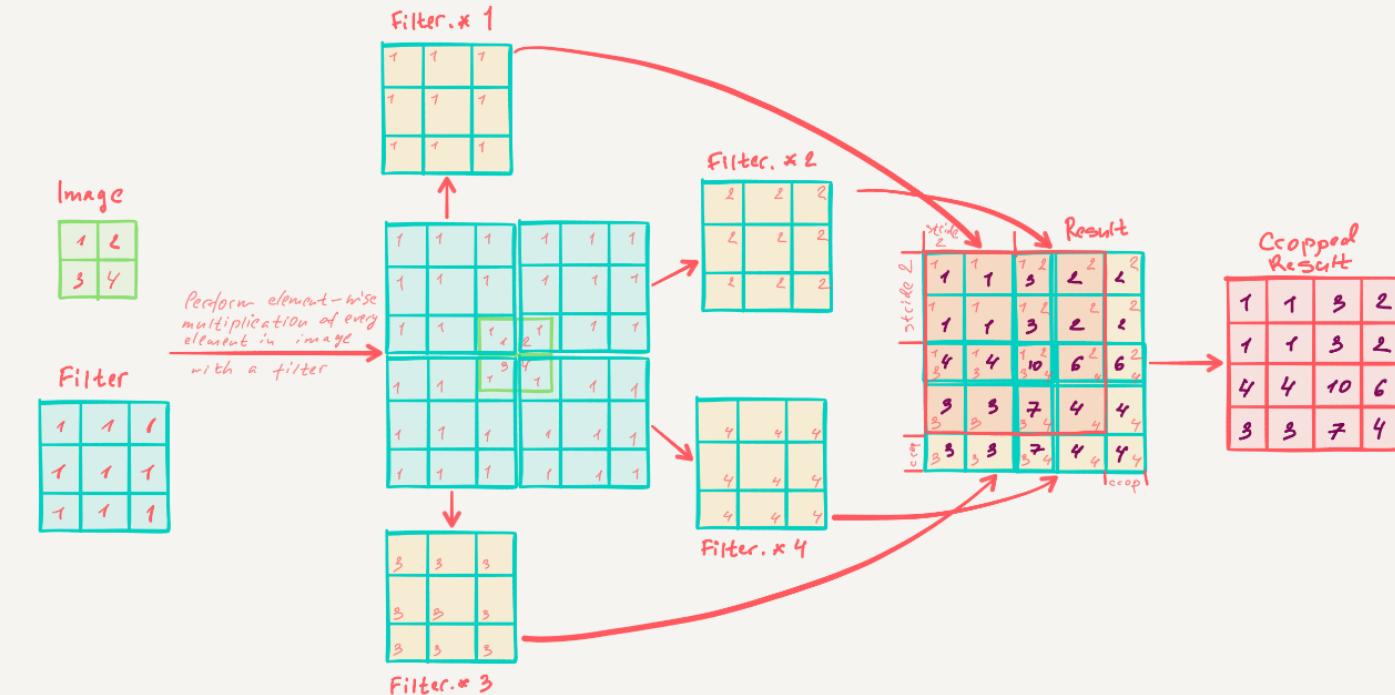
Upsampling

Transposed convolutions – also called fractionally strided convolutions – work by swapping the forward and backward passes of a convolution

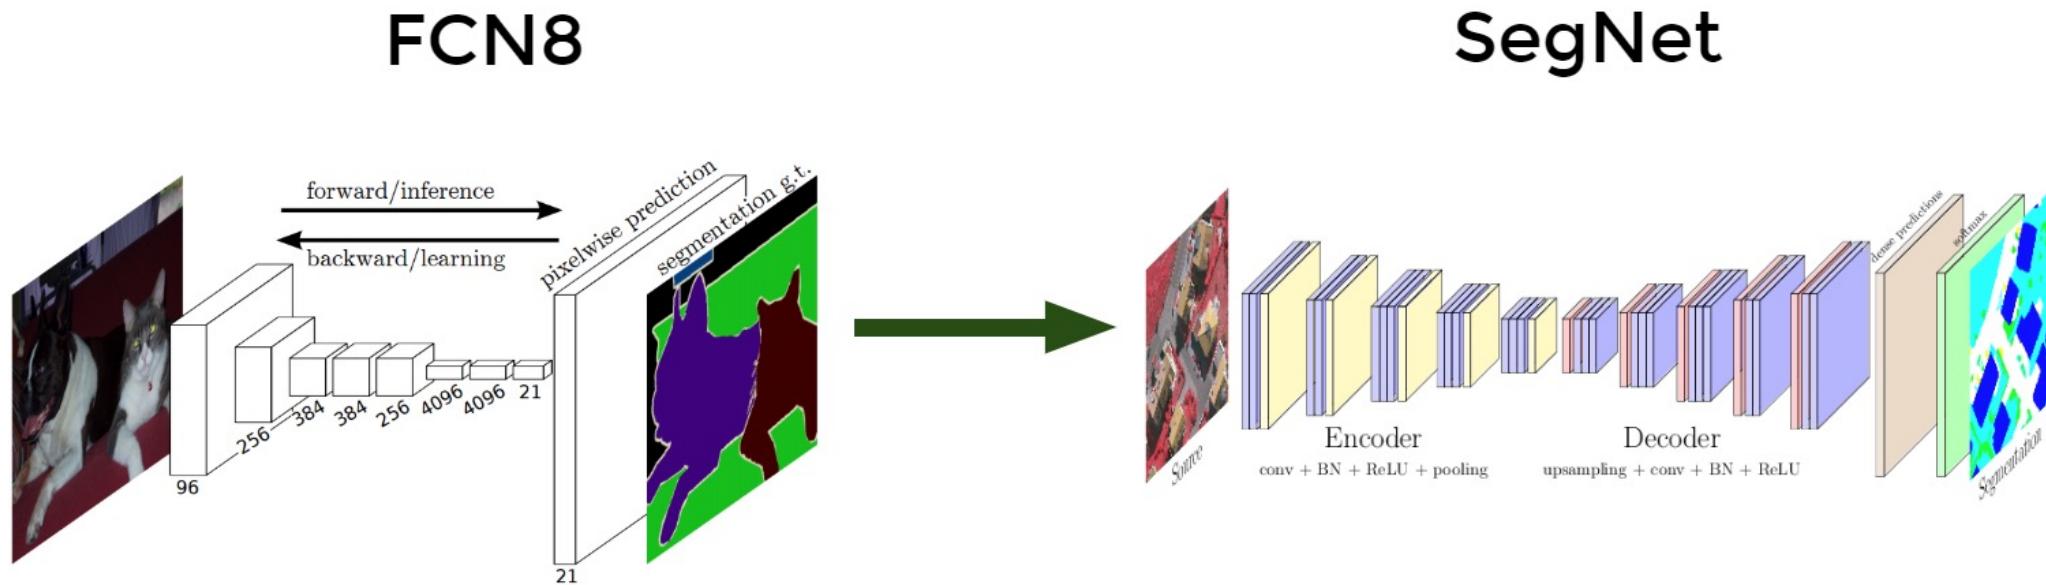


Upsampling

conv2d - transpose



FCN8 to SegNet

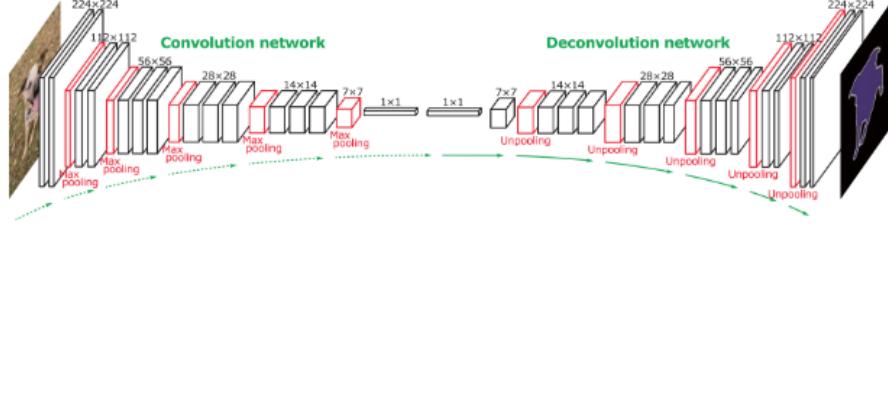


Заменить Upsampling на иерархический Upsampling

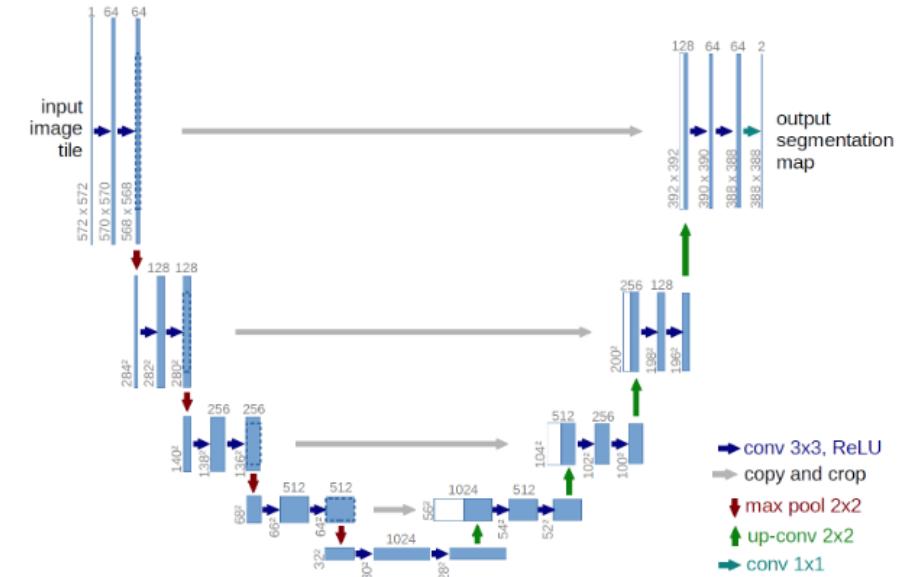
V. Badrinarayanan, A. Kendall, and R. Cipolla, "Segnet: A deep convolutional encoder-decoder architecture for image segmentation," arXiv:1511.00561, 2015

Upsampling

SegNet



UNet

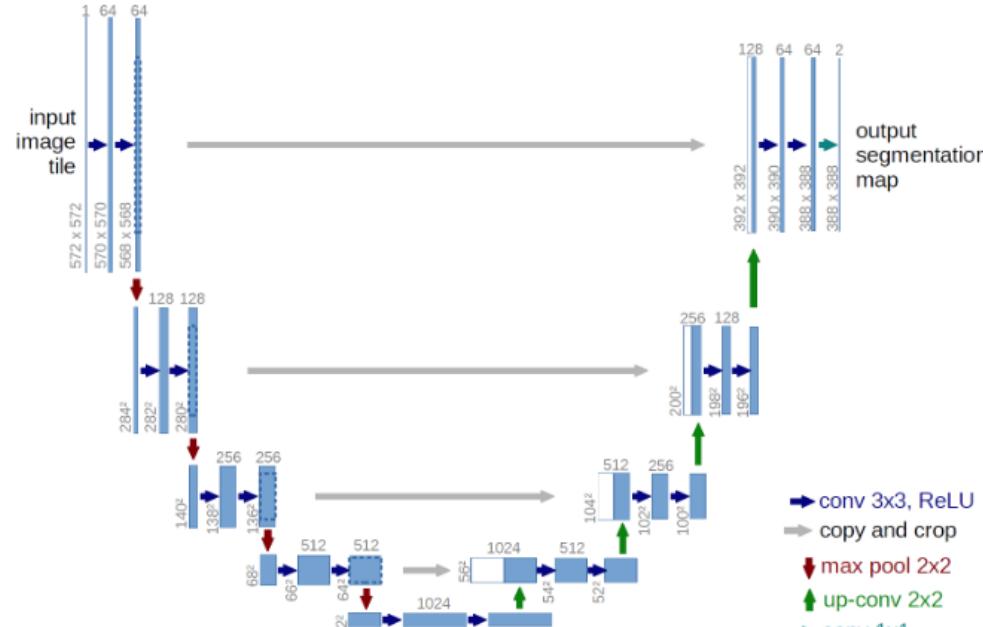


Added skip connections

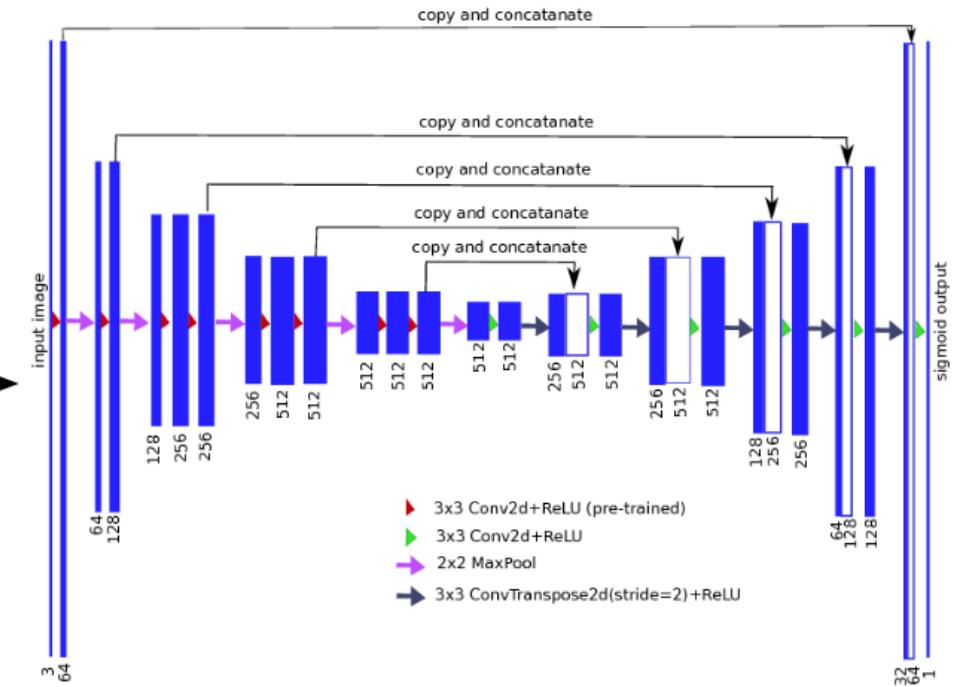
O. Ronneberger P. Fischer T. Brox "U-net: Convolutional networks for biomedical image segmentation" Proc. Med. Image Comput. Comput.-Assisted

Intervention pp. 234-241 2015.

Unet => TernausNet

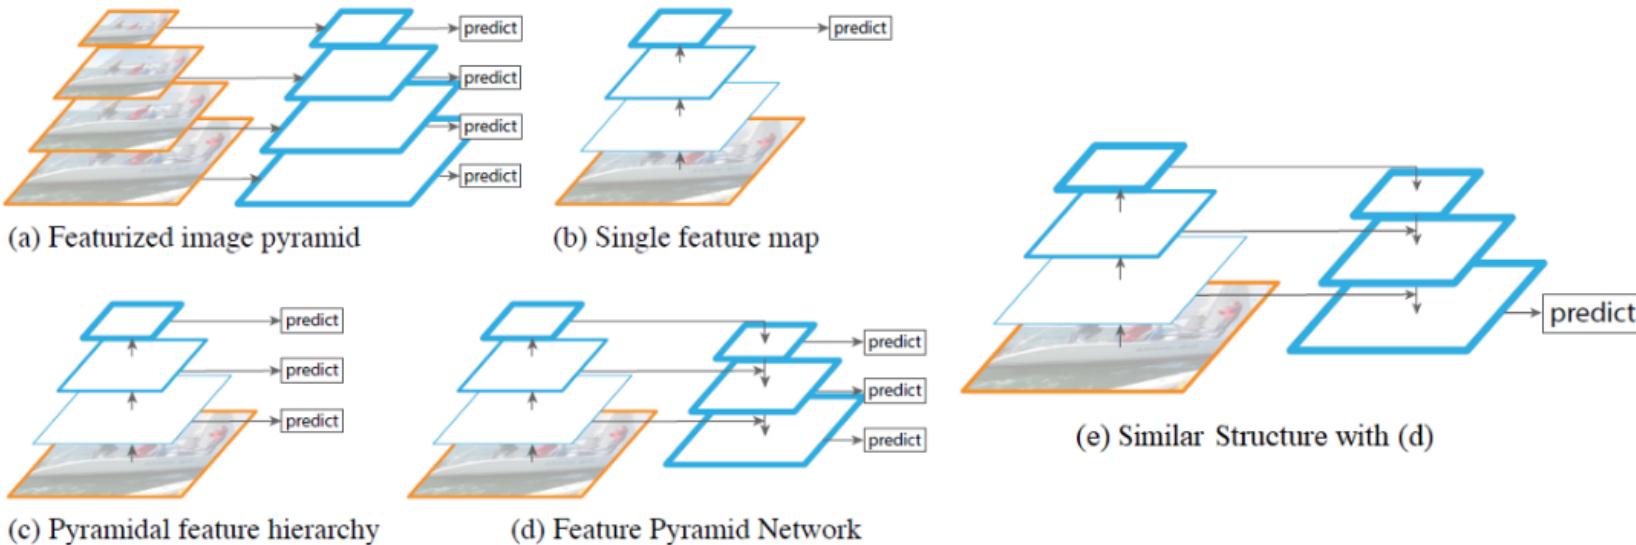


Text →



Энкодер инициализируем весами с ImageNet

Feature Pyramid Networks (FPN)

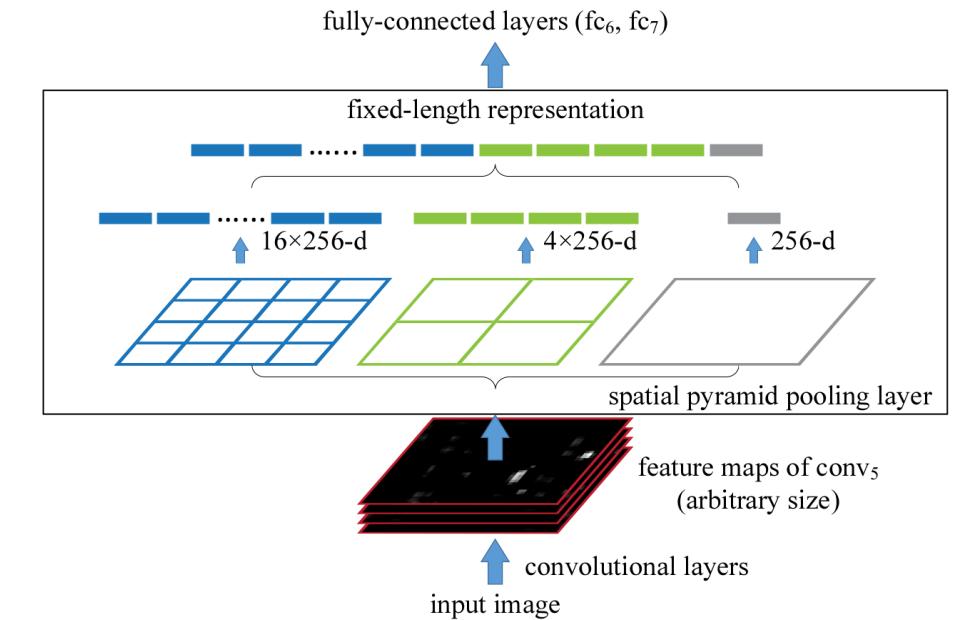
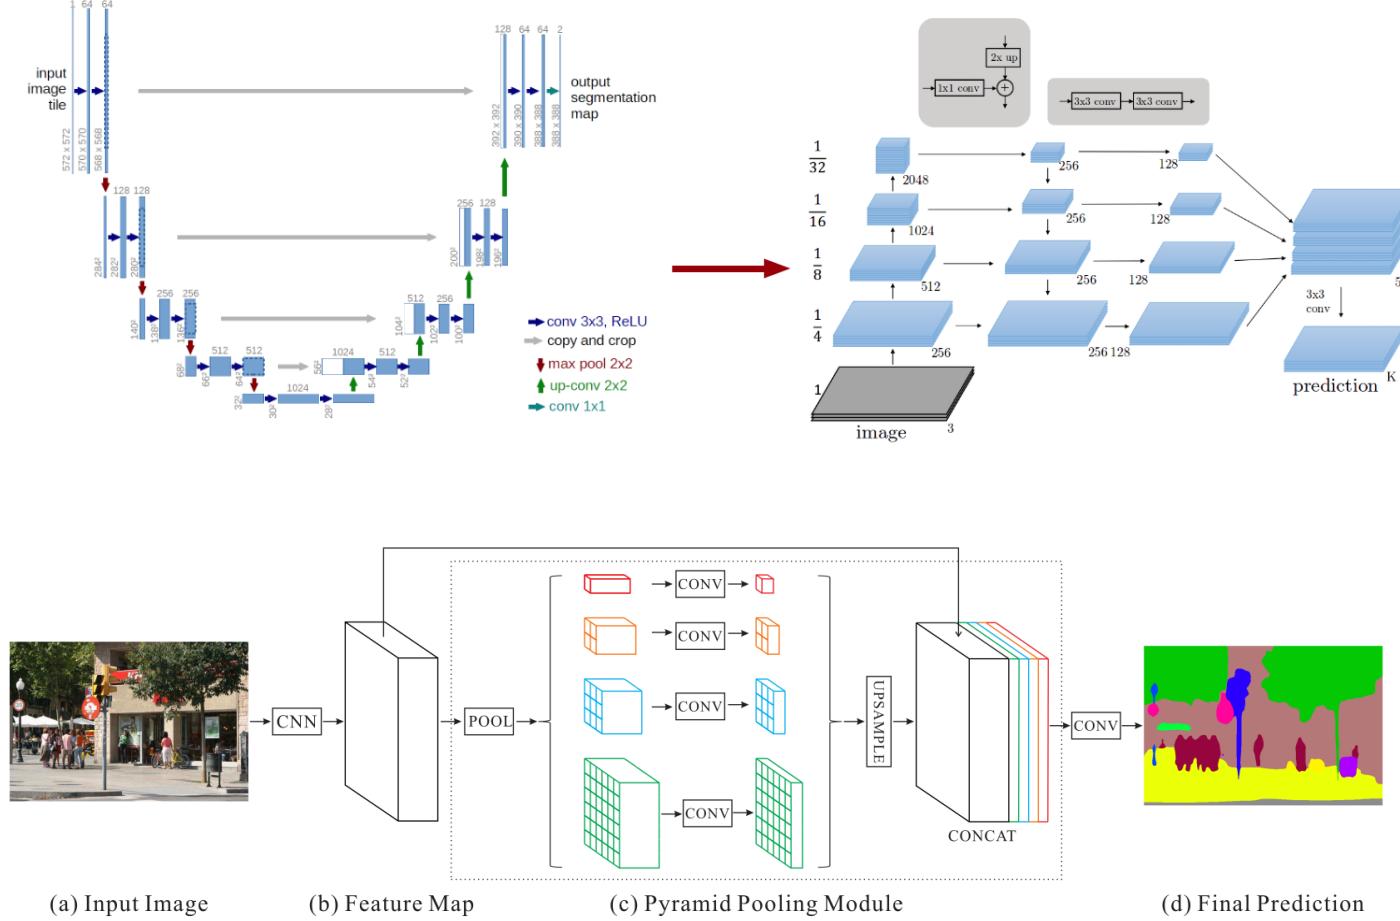


1. Легко добавить во многие архитектуры.
2. Помогает с multiscale

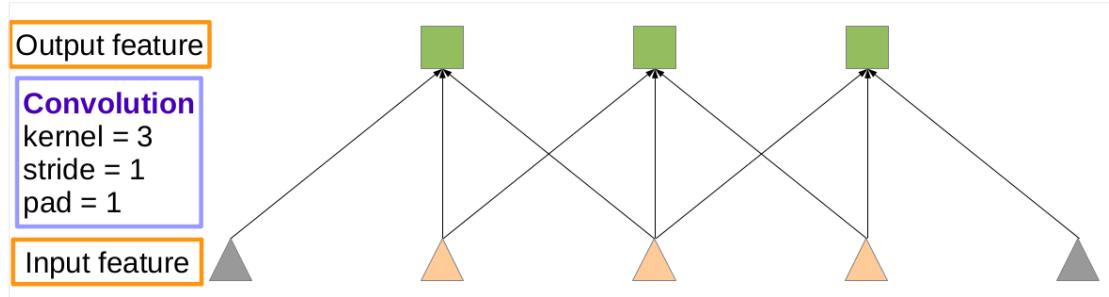
Tsung-Yi Lin, Piotr Dollar, Ross Girshick, Kaiming He, Bharath Hariharan, Serge Belongie; The IEEE Conference on Computer Vision and Pattern Recognition

(CVPR), 2017, pp. 2117-2125

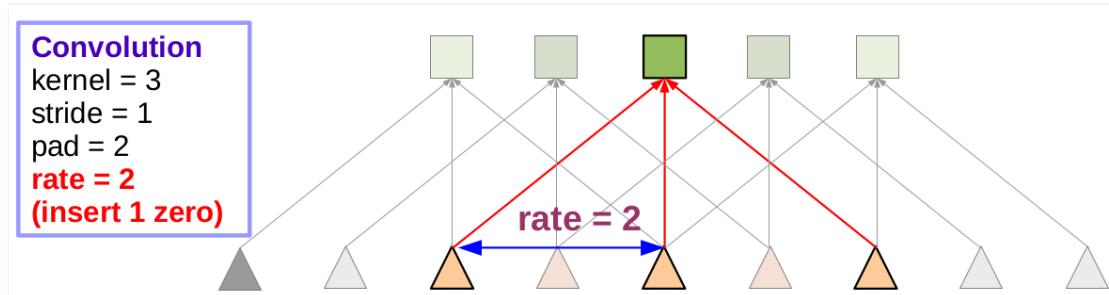
Unet + FPN



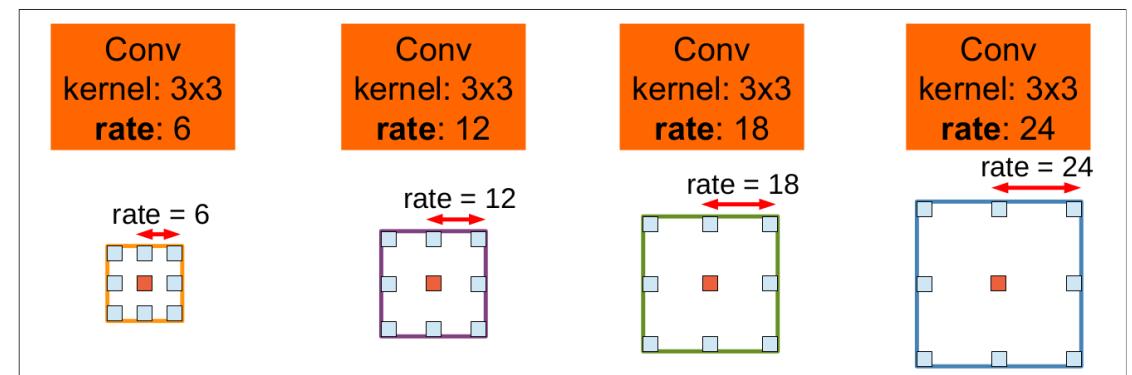
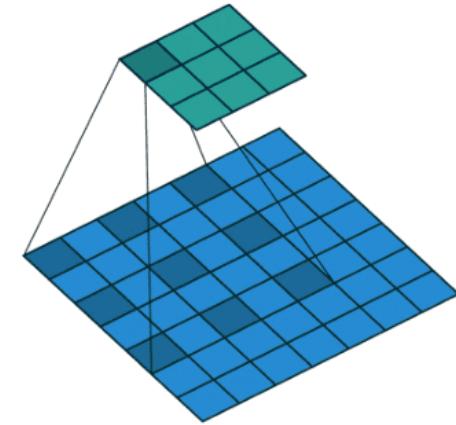
Atrous Spatial Pyramid Pooling



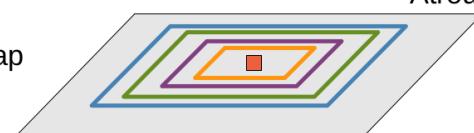
(a) Sparse feature extraction



(b) Dense feature extraction

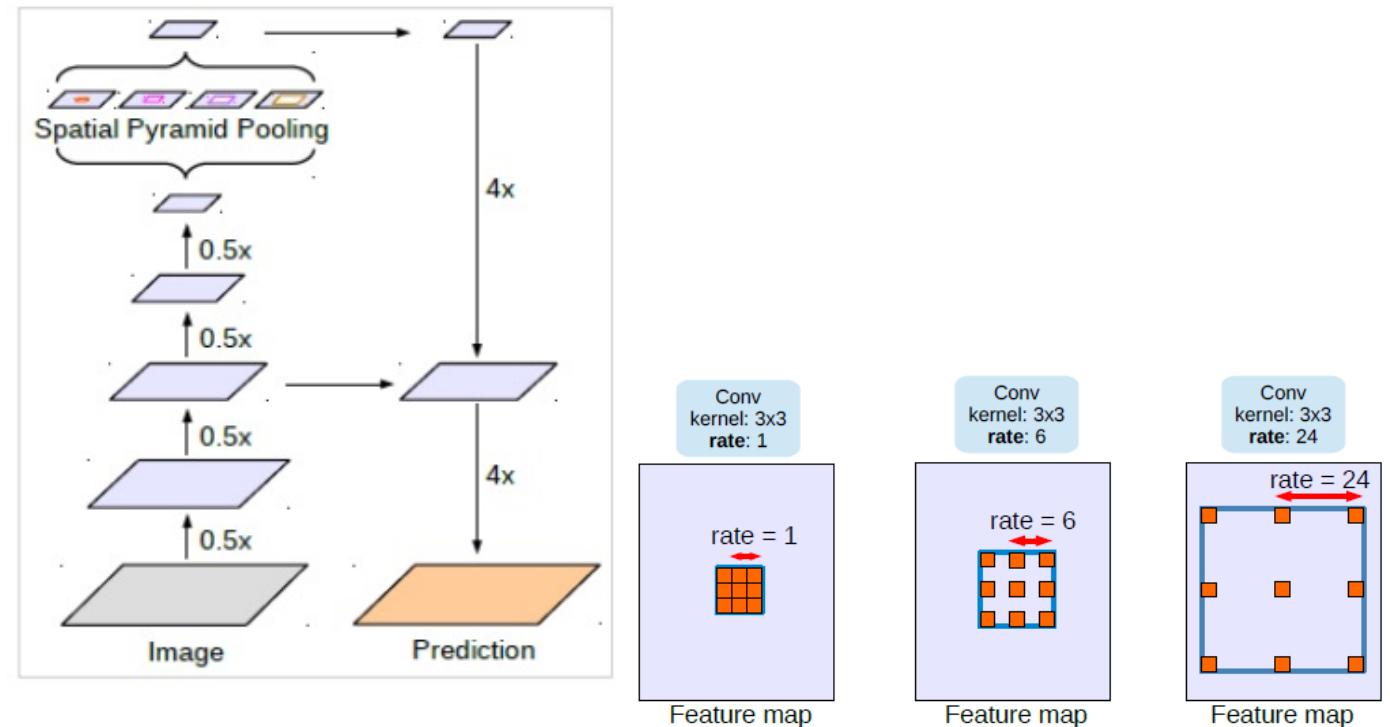
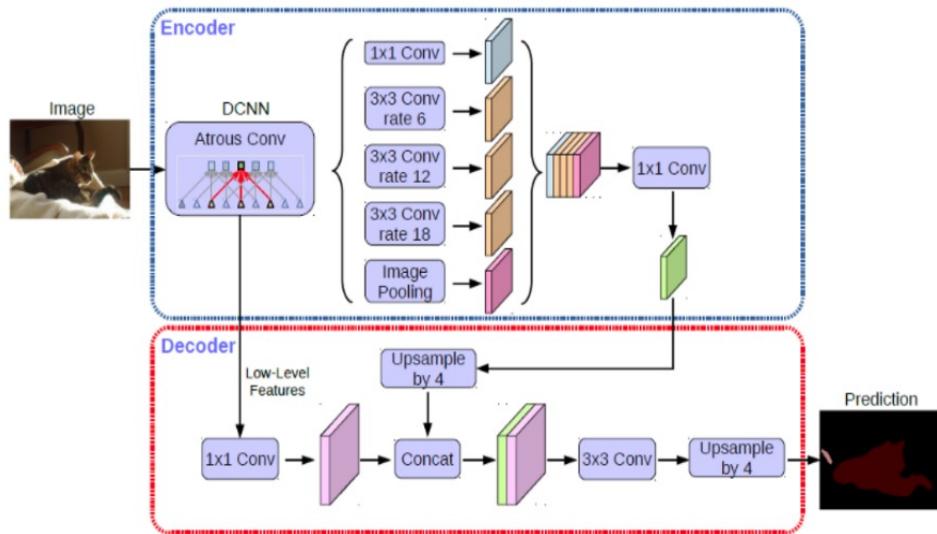


Input Feature Map



Atrous Spatial Pyramid Pooling

DeepLabV3



Atrous Separable Convolution

Segmentation Loss Function

Каждый пиксель классификатор =>
Categorical / Binary Cross Entropy(CCE,
BCE)

$$CCE = \sum_c p(x) \log q(x)$$

Но! Метрика Dice / Jaccard
Dice / Jaccard недифференцируемы =>
Soft Dice / Soft Jaccard
и добавляем в loss

$$LOSS = BCE - \ln(DICE)$$

$$BCE = - \sum_i (y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i))$$

$$DICE = 2 \frac{\sum_i y_i p_i}{\sum_u y_i + \sum p_i}$$

Lovasz-Softmax loss
Использовать для FineTune

Berman, M., Rannen Triki, A., Blaschko, M.B.: The lovász-softmax loss: a tractable surrogate for the optimization of the intersection-over-union measure in neural networks. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 4413–4421 (2018)

Label smoothing

Было

$$\begin{aligned} L &= \sum_{i=1}^n H_i(p, q_\theta) \\ &= -\sum_{i=1}^n \sum_{y=1}^K p(y|x_i) \log q_\theta(y|x_i) \end{aligned}$$

Вместо использования вектора с одним активным битом мы вводим шумовое распределение $u(y|x)$ вида $(y|\theta)$. Наша новая истинная метка для данных (x_i, y_i) ($i=1, \dots, N$) будет

$$\begin{aligned} p'(y|x_i) &= (1 - \varepsilon)p(y|x_i) + \varepsilon u(y|x_i) \\ &= \begin{cases} 1 - \varepsilon + \varepsilon u(y|x_i) & \text{if } y = y_i \\ \varepsilon u(y|x_i) & \text{otherwise} \end{cases} \\ \varepsilon \in [0, 1] \quad \sum_{y=1}^K p'(y|x_i) &= 1 \end{aligned}$$

Мы используем эту новую истинную метку вместо метки с одним активным битом в нашей функции потерь.

$$\begin{aligned} L' &= -\sum_{i=1}^n \sum_{y=1}^K p'(y|x_i) \log q_\theta(y|x_i) \\ &= -\sum_{i=1}^n \sum_{y=1}^K [(1 - \varepsilon)p(y|x_i) + \varepsilon u(y|x_i)] \log q_\theta(y|x_i) \end{aligned}$$

Как закодировать в обычном случае

$$y_k^{LS} = y_k(1 - \alpha) + \frac{\alpha}{K}$$

```
import torch
import torch.nn as nn

class LabelSmoothingLoss(nn.Module):
    def __init__(self, smoothing=0.0):
        super(LabelSmoothingLoss, self).__init__()
        self.smoothing = smoothing

    def forward(self, x, target):
        logprobs = torch.nn.functional.log_softmax(x, dim=-1)
        nll_loss = -logprobs.gather(dim=-1, index=target.unsqueeze(1)).squeeze(1)
        smooth_loss = -logprobs.mean(dim=-1)
        loss = (1 - self.smoothing) * nll_loss + self.smoothing * smooth_loss
        return loss.mean()
```

$$\begin{aligned} L' &= \sum_{i=1}^n \left\{ (1 - \varepsilon) \left[-\sum_{y=1}^K p(y|x_i) \log q_\theta(y|x_i) \right] + \varepsilon \left[-\sum_{y=1}^K u(y|x_i) \log q_\theta(y|x_i) \right] \right\} \\ &= \sum_{i=1}^n \left[(1 - \varepsilon) H_i(p, q_\theta) + \varepsilon H_i(u, q_\theta) \right] \end{aligned}$$

Exponential Moving Average

Экспоненциальное скользящее среднее (EMA) - это техника, используемая в глубоком обучении, чтобы стабилизировать процесс обучения, сглаживая колебания в обучающих данных.

$$\text{EMA}_t = \begin{cases} p_1 & \text{if } t = 1 \\ \alpha p_t + (1 - \alpha) \text{EMA}_{t-1} & \text{else} \end{cases}$$

Псевдокод

```
# Initialize the EMA parameters
ema_alpha = 0.99
ema_weights = model.get_weights()

# Iterate through the training data
for i in range(num_epochs):
    for batch in training_data:
        # Perform forward and backward pass on the batch
        loss = model.train_on_batch(batch)

        # Update the model weights with stochastic gradient descent
        weights = model.get_weights()
        new_weights = [w - learning_rate * dw for w, dw in zip(weights, gradient
s)]

        # Update the EMA weights
        ema_weights = [ema_alpha * w + (1 - ema_alpha) * new_w for w, new_w in z
ip(ema_weights, new_weights)]

        # Set the model weights to the EMA weights
        model.set_weights(ema_weights)
```

```
import torch
import torch.nn as nn
import torch.optim as optim
from torch.optim.swa_utils import AveragedModel, SWALR

# define your neural network
class Net(nn.Module):
    def __init__(self):
        super(Net, self).__init__()
        self.fc1 = nn.Linear(784, 100)
        self.fc2 = nn.Linear(100, 10)

    def forward(self, x):
        x = x.view(-1, 784)
        x = nn.functional.relu(self.fc1(x))
        x = self.fc2(x)
        return x

# define your optimizer
optimizer = optim.SGD(net.parameters(), lr=0.01)

# define the EMA
ema_model = AveragedModel(net)

# define the SWA learning rate scheduler
swa_scheduler = SWALR(optimizer, swa_lr=0.05)

# train your model
for epoch in range(num_epochs):
    for i, (inputs, labels) in enumerate(train_loader):
        optimizer.zero_grad()
        outputs = net(inputs)
        loss = loss_function(outputs, labels)
        loss.backward()
        optimizer.step()
        ema_model.update_parameters(net)
        swa_scheduler.step()

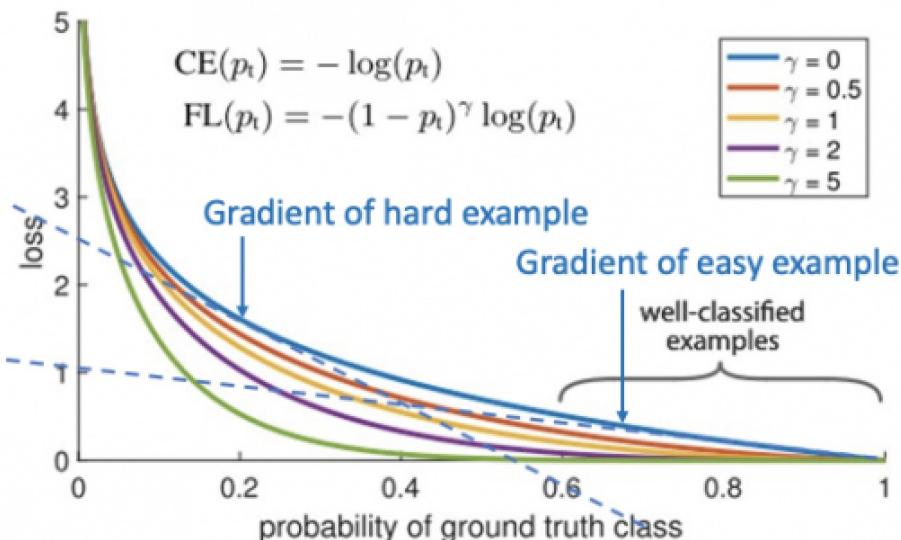
# evaluate your model using the EMA
ema_model.eval()
with torch.no_grad():
    for inputs, labels in test_loader:
        outputs = ema_model(inputs)
        _, predicted = torch.max(outputs.data, 1)
        total += labels.size(0)
        correct += (predicted == labels).sum().item()
accuracy = 100 * correct / total
```

Focal Loss

Фокальная функция потерь - это функция потерь, разработанная для задач обнаружения объектов в глубоком обучении.

Она разработана для решения проблемы несбалансированности классов, когда количество примеров в одном классе значительно превышает количество примеров в других классах.

$$FL(p_t) = -(1 - p_t)^\gamma \log(p_t)$$



```
def focal_loss(y_true, y_pred, alpha=0.25, gamma=2.0):
    # Convert predictions to probabilities
    y_pred = K.softmax(y_pred, axis=-1)
    # Calculate the cross entropy loss
    ce_loss = -y_true * K.log(y_pred)
    # Calculate the focal loss
    pt = K.sum(y_true * y_pred, axis=-1)
    fl_loss = alpha * K.pow(1 - pt, gamma) * ce_loss
    return K.mean(fl_loss)
```

Метрики

Intersection over Union (IoU)
or Jaccard Index

$$= \frac{\text{Area of Overlap}}{\text{Area of Union}}$$


Чаще всего используют
Dice - особенно в
медицинских снимках
и Jaccard (IoU)

Table 1. The three similarity coefficients

Similarity Coefficient (X, Y)	Actual Formula
Dice Coefficient	$\frac{ X \cap Y }{ X + Y }$
Cosine Coefficient	$\frac{ X \cap Y }{ X ^{1/2} \cdot Y ^{1/2}}$
Jaccard Coefficient	$\frac{ X \cap Y }{ X + Y - X \cap Y }$

Заключение

Рассмотрена постановка задачи сегментации изображений

Изучены базовые подходы архитектур encoder-decoder

pooling

upconv, upsampling

unet

Рассмотрены техники обучения моделей

Label smoothing

EMA

Focal loss

Ссылки

Kaggle - [Airbus Ship Detection Challenge](#), пример на задачу
instance segmentation